UNIVERSIDAD PERUANA
CAYETANO HEREDIA

Título:

“Predicción de deserción de estudiantes universitarios”

Docentes:

Josue Angel Mauricio Salazar

Jeremy Karsen Holguin Mori

Integrantes:

Matias Alfredo Vidal Elliot

Victor Daniel Rivera Torres

Jesus Anselmo Morales Alvarado

Lima - Perú

2026

1. Introducción:

La educación universitaria, también conocida como educación superior, hace referencia a la formación académica posterior a la educación secundaria. Esta etapa resulta fundamental tanto a nivel individual como a nivel macroeconómico. En el plano individual, permite el desarrollo de conocimientos y habilidades, que permiten mayores oportunidades laborales, empleos más estables y mejores ingresos a lo largo de la vida del individuo [1] [2]. A nivel macroeconómico, diversos estudios han evidenciado la existencia de una correlación entre el nivel educativo y la competitividad económica del país [3].

A pesar de los múltiples beneficios asociados a la educación superior, un número significativo de estudiantes no logra culminar sus estudios. Este fenómeno es conocido como deserción universitaria. En el Perú, la tasa de deserción universitaria se sitúa aproximadamente en un 18% [4]. Entre las principales causas se encuentran las limitaciones económicas, el bajo rendimiento académico y diversos factores psicosociales [5].

Las consecuencias de la deserción son relevantes en distintos niveles. A nivel individual, puede generar efectos psicológicos asociados al fracaso académico, así como pérdidas económicas, dado que la educación superior implica una inversión considerable que no llega a concretarse en los beneficios esperados. A nivel institucional, la deserción afecta negativamente la reputación y el prestigio de las universidades [6]. Por ello, resulta fundamental no solo monitorear, sino también gestionar y reducir estos niveles de abandono.

En este contexto, surge la necesidad de desarrollar herramientas que permitan identificar de manera temprana a los estudiantes que se encuentran en situaciones vulnerables, para evitar su deserción. En particular, las técnicas de machine learning representan una alternativa prometedora para abordar este problema. Como se mencionó anteriormente, las causas del abandono estudiantil son complejas y multifactoriales. En este sentido los algoritmos usados en machine learning permiten analizar grandes volúmenes de datos y múltiples variables, facilitando la construcción de modelos predictivos [7].

Por ello, el objetivo del presente proyecto es desarrollar y evaluar un modelo de clasificación capaz de predecir la deserción estudiantil utilizando el dataset “Predict Student's Dropout and Academic Success”.

2. Estado del arte

La predicción de la deserción académica mediante modelos de *machine learning* ha sido ampliamente estudiada tanto en el Perú como en el ámbito internacional. El análisis comparativo de estos trabajos permite identificar un patrón claro: el desempeño predictivo de un modelo no depende únicamente del algoritmo utilizado, sino también, de manera determinante, de la calidad y relevancia de las variables empleadas.

En el contexto peruano, destaca la investigación titulada *“Machine Learning Application in University Management: Classification Model for Dropping Out of Engineering Students in Peru”*. En este estudio se desarrolló un modelo de red neuronal profunda con ocho capas ocultas, aplicado a datos de estudiantes de ingeniería de la Universidad Nacional de Ingeniería. A pesar de la complejidad del modelo, este alcanzó una precisión aproximada del 67%. Los autores atribuyen este desempeño limitado no a la arquitectura del modelo, sino a la selección de variables. En particular, las variables utilizadas describían principalmente el perfil previo al ingreso universitario, sin capturar de manera adecuada la situación académica actual del estudiante. Asimismo, algunas variables resultaban poco informativas, como la nacionalidad, debido a su baja variabilidad en la muestra. Este estudio evidencia la importancia de contar con variables representativas y relevantes para mejorar la capacidad predictiva [8].

Un segundo estudio, titulado *“Model for the Prediction of Dropout in Higher Education in Peru Applying Machine Learning Algorithms: Random Forest, Decision Tree, Neural Network and Support Vector Machine”*, presenta un enfoque comparativo entre distintos algoritmos. En esta investigación se evaluaron modelos como Random Forest, árboles de decisión, redes neuronales y máquinas de soporte vectorial, utilizando datos de 385 estudiantes de universidades públicas y privadas del Perú. La información fue recolectada mediante una encuesta estructurada que

incluyó seis categorías: datos generales, información sobre la carrera y la universidad, educación preuniversitaria, entorno familiar, variables cognitivas y variables afectivas. A diferencia del estudio anterior, este conjunto de variables permitió capturar de manera más completa tanto el contexto socioeconómico como la experiencia académica del estudiante. El mejor desempeño fue obtenido por el modelo Random Forest, con un AUC de 0.9623 y una precisión del 93.8%. Resulta relevante destacar que este modelo, de complejidad moderada, superó a otros más sofisticados, lo que refuerza la importancia de una adecuada selección de variables [9].

Esta conclusión también se ve respaldada por estudios internacionales, como *"Perspectives to Predict Dropout in University Students with Machine Learning"*. En este trabajo se evaluaron diversos algoritmos, incluyendo Random Forest, redes neuronales, máquinas de soporte vectorial y regresión logística. Las variables consideradas abarcaron características sociodemográficas, historial académico por semestre, información sobre becas y financiamiento, así como variables relacionadas con el programa de estudio, lo que permitió modelar de forma más dinámica la trayectoria del estudiante. En este contexto, el modelo Random Forest alcanzó una tasa de detección de desertores del 91% y una sensibilidad del 87%. No obstante, otros modelos presentaron valores de desempeño similares en términos del coeficiente kappa, lo que sugiere que, con una adecuada definición del problema y una selección pertinente de variables, modelos más simples pueden alcanzar resultados comparables a los de modelos más complejos [10].

En conjunto, estos estudios evidencian que la selección y calidad de las variables constituye un factor clave en la predicción de la deserción estudiantil, incluso por encima de la complejidad del modelo utilizado.

3. Metodología

a. Descripción de los datos:

El dataset utilizado es "Predict Students' Dropout and Academic Success", disponible en el repositorio UCI Machine Learning Repository. Contiene 4,424 registros correspondientes a estudiantes

de educación superior de una institución portuguesa, con 36 variables de entrada que abarcan características demográficas del estudiante (edad al inscribirse, género, nacionalidad), información socioeconómica (situación de deuda, tenencia de beca, estado de pago de matrícula), datos académicos previos al ingreso (nota de admisión, calificación previa) y desempeño académico durante el primer y segundo semestre (unidades curriculares inscritas, aprobadas y calificación promedio). La variable objetivo ("Target") presenta tres categorías: Dropout, Graduate y Enrolled.

b. Preprocesamiento:

Dado que los estudiantes con estado "Enrolled" aún no cuentan con un resultado académico definitivo, se optó por excluirlos del análisis, reduciendo el dataset a 3,630 registros. La variable objetivo fue recodificada de forma binaria: Dropout = 0 y Graduate = 1, resultando en una distribución de aproximadamente 39% y 61% respectivamente.

Las variables categóricas (estado civil, modalidad de solicitud, curso, nacionalidad, y cualificación de los padres) fueron transformadas mediante codificación one-hot, con eliminación de la primera categoría para evitar multicolinealidad. Este proceso se aplicó exclusivamente sobre el conjunto de entrenamiento, y las columnas resultantes fueron replicadas en el conjunto de prueba mediante alineación de columnas, garantizando la ausencia de data leakage.

El dataset no presenta valores nulos, por lo que no fue necesario aplicar estrategias de imputación. Las variables numéricas fueron estandarizadas mediante Z-score (media cero, desviación estándar uno). Los parámetros de escalado (media y desviación estándar) fueron estimados únicamente sobre el conjunto de entrenamiento y aplicados posteriormente al conjunto de prueba, siguiendo el principio de no filtrar información del test durante el entrenamiento.

Finalmente, se añadió una columna de unos al inicio de la matriz de features para representar el término de sesgo (bias) del modelo, evitando la necesidad de tratarlo como un parámetro separado.

c. **Análisis Exploratorio de Datos:**

El análisis exploratorio se realizó en tres niveles. Primero, se examinó la distribución de la variable objetivo, confirmando el leve desbalance de clases mencionado. Segundo, se analizaron las variables académicas de mayor correlación con el target: las unidades curriculares aprobadas y la nota promedio del segundo semestre presentaron las correlaciones absolutas más altas (0.65 y 0.61 respectivamente), seguidas por las variables equivalentes del primer semestre. Esto sugiere que el desempeño durante la trayectoria universitaria es más predictivo que las características previas al ingreso, en línea con los hallazgos del Estado del Arte. Tercero, se exploró el impacto de variables socioeconómicas: los estudiantes deudores presentan una mayor proporción de deserción, mientras que los becarios muestran mejores tasas de graduación. La distribución de la edad al inscribirse indica que los desertores tienden a ser ligeramente mayores, posiblemente asociado a mayor carga de responsabilidades externas.

d. **Modelo utilizado:**

Se implementó un modelo de Regresión Logística desde cero, sin uso de frameworks de modelamiento. La regresión logística modela la probabilidad de que un estudiante pertenezca a la clase Graduate mediante la función sigmoide:

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \text{ donde } z = X\theta$$

La función de costo utilizada es la Binary Cross-Entropy (Log-Loss):

$$J(\theta) = -\frac{1}{m}\sum_{i=1}^{m}\left[y_i \cdot \log\left(\hat{y}_i\right) + (1 - y_i) \cdot \log\left(1 - \hat{y}_i\right)\right]$$

donde m es el número de muestras, y_i es la etiqueta real y $\hat{h}_i = \sigma(X_i\theta)$ es la probabilidad predicha. Se agrega un término de estabilidad numérica (1e-15) para evitar logaritmo de cero.

e. **Entrenamiento y optimización:**

El conjunto de datos fue dividido en 80% entrenamiento (2,904 muestras) y 20% prueba (726 muestras) mediante permutación aleatoria con semilla fija (np.random.seed(42)) para reproducibilidad.

Los parámetros θ fueron optimizados mediante Gradiente Descendente batch. La regla de actualización es:

$$\theta := \theta - \alpha \cdot \frac{1}{m} \cdot X^T \cdot (\hat{y} - y)$$

donde α es la tasa de aprendizaje. Se realizó un experimento numérico evaluando cuatro valores de $\alpha \in \{0.001, 0.01, 0.05, 0.1\}$ durante 500 iteraciones. Se seleccionó $\alpha = 0.01$ por presentar convergencia estable sin oscilaciones. El entrenamiento final se ejecutó con un máximo de 1,000 iteraciones, incorporando un criterio de parada anticipada: si el cambio absoluto en el costo entre iteraciones consecutivas es menor a 1×10^{-6}, el algoritmo se detiene para evitar iteraciones innecesarias una vez alcanzada la convergencia.

Los parámetros θ fueron inicializados en cero.

f. **Evaluación:**

Dado el desbalance de clases presente en el dataset, la evaluación del modelo no se limitó al accuracy. Se calcularon manualmente las siguientes métricas a partir de la matriz de confusión: Accuracy, Precision, Recall (sensibilidad), F1-Score y Especificidad. El umbral de decisión utilizado fue 0.5 sobre la probabilidad predicha.

4. Bibliografía

1. UNESCO. (s.f.). *La educación superior*. https://www.unesco.org/es/higher-education/need-know
2. Naciones Unidas. (s.f.). *Educación superior*. https://www.un.org/es/impacto-académico/educación-superior
3. Macías-Acosta, R. (2024). *El impacto de la educación superior en la competitividad económica de México*. ResearchGate. https://www.researchgate.net/publication/378394055
4. Ministerio de Educación del Perú. (2021, diciembre 14). *Se reduce tasa de deserción en las universidades privadas*. Gobierno del Perú. https://www.gob.pe/institucion/minedu/noticias/350777
5. Quispe, G. (2025). *Artículo sobre deserción universitaria*. *Paideia*, Universidad Ricardo Palma. https://revistas.urp.edu.pe/index.php/Paideia/article/view/7782/12103
6. Valero, J., Navarro, A., Larios, A., Julca, J. (2022). *Artículo sobre deserción e instituciones*. Dialnet. https://dialnet.unirioja.es/servlet/articulo?codigo=8526463
7. IBM. (s.f.). *¿Qué es el machine learning?* IBM Think. https://www.ibm.com/es-es/think/topics/machine-learning
8. Flores, R., Turpo, O., & Salas, R. (2023). *Model for the prediction of dropout in higher education in Peru applying machine learning algorithms: Random Forest, Decision Tree, Neural Network and Support Vector Machine*. ResearchGate. https://www.researchgate.net/publication/371403676
9. Alfaro, C., & otros. (2023). *Machine learning application in university management: Classification model for dropping out of engineering students in Peru*. En *Proceedings of LACCEI 2023*. Latin American and Caribbean Consortium of Engineering Institutions.

https://laccei.org/LACCEI2023-BuenosAires/papers/Contribution_1332_a.pdf

10. Ortiz-Lozano, J. M., Rua-Vásquez, A., & Reinoso-Lastra, J. F. (2018). *Perspectives to predict dropout in university students with machine learning*. En *2018 IEEE International Work Conference on Bioinspired Intelligence (IWOBI)*. IEEE. https://doi.org/10.1109/iwobi.2018.8464191